

UNIFEI
Universidade Federal de Itajubá

PROGRAMAÇÃO PARA CIÊNCIAS DE DADOS

HELENA FERNANDES MORAIS PESSOA

RELATÓRIO DO PROJETO FINAL

ITAJUBÁ
2026

Sumário

1. RESUMO 3
2. INTRODUÇÃO 4
3. METODOLOGIA 4
3.7 AVALIAÇÃO DO MODELO 15
3.8 ACERTOS E ERROS DAS PREVISÕES 16
3.10 ANÁLISE DO RETORNO FINANCEIRO 17
3.11 PERDAS FINANCEIRAS 17
3.12 GANHOS FINANCEIROS 18
3.13 RETORNO FINANCEIRO GERAL 18
4. CONCLUSÃO E RESULTADOS 19
5. REFERÊNCIAS 20

1. RESUMO

O presente trabalho teve como objetivo desenvolver um modelo de Machine Learning capaz de prever a direção diária da ação PETR4 negociada na B3, utilizando dados históricos do mercado financeiro. Inicialmente, foi realizada a coleta e o tratamento dos dados, seguidos pela etapa de engenharia de atributos, na qual foram criadas variáveis derivadas da série temporal, como médias móveis, volatilidade, amplitude diária e variações de volume.

Após o pré-processamento, foi definida uma variável alvo binária, classificando cada pregão em alta ou baixa de acordo com a relação entre os preços de abertura e fechamento. Em seguida, foi aplicado o algoritmo Random Forest para realizar a tarefa de classificação e prever a direção dos movimentos do ativo.

Durante a análise exploratória, foram avaliadas as distribuições das variáveis, as correlações entre os atributos e o comportamento histórico do preço da ação. Os resultados obtidos demonstraram elevado desempenho do modelo, alcançando acurácia de 98,29%, precisão de 96,49%, F1-Score de 98,21% e especificidade de 96,77%.

Além da avaliação estatística, foi realizada uma análise financeira baseada nas previsões do modelo. A estratégia simulada apresentou retorno acumulado de 58,22% no período analisado, com taxa de operações vencedoras de aproximadamente 96,49%, evidenciando a capacidade do modelo em identificar padrões relevantes da série temporal estudada.

Os resultados obtidos demonstram que a aplicação de técnicas de Engenharia de Atributos e Machine Learning pode contribuir para a construção de modelos preditivos eficientes no mercado financeiro, servindo como ferramenta de apoio à tomada de decisão em operações de investimento.

Palavras-chave: Machine Learning; Random Forest; Mercado Financeiro; PETR4; Série Temporal; Ciência de Dados; Previsão de Ações.

2. INTRODUÇÃO

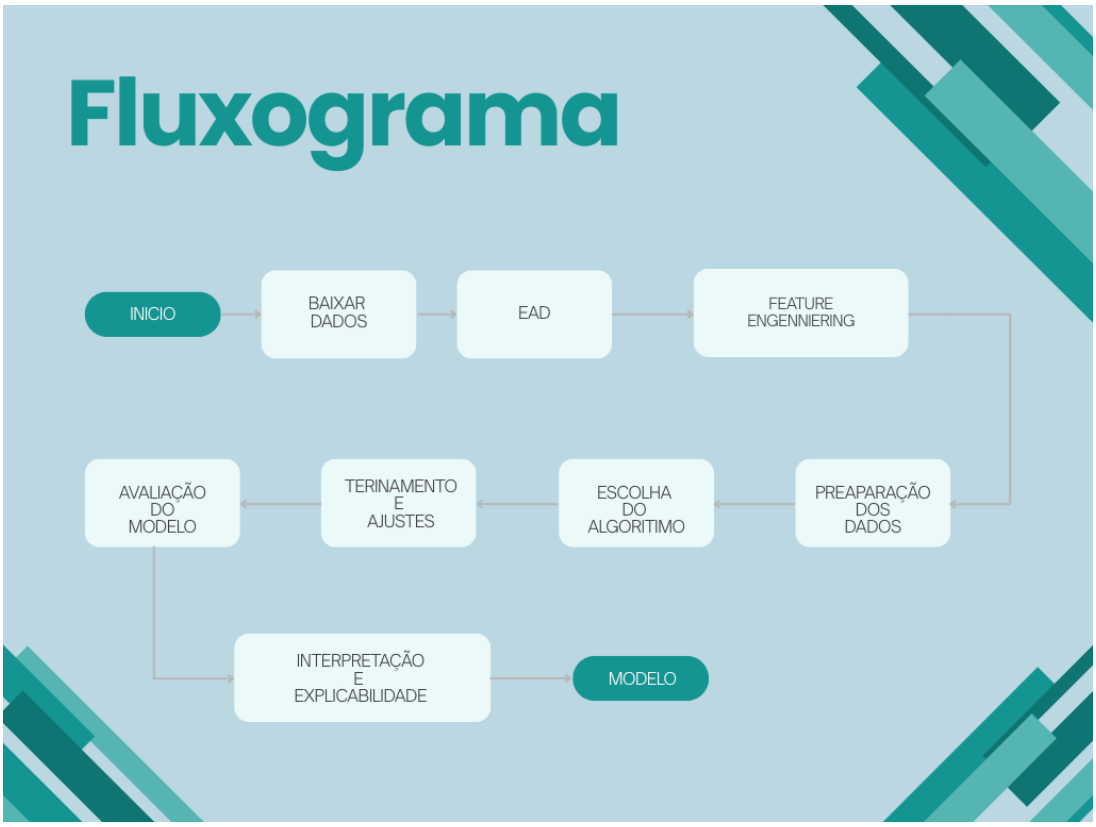
Este relatório tem como objetivo apresentar o desenvolvimento, a metodologia aplicada e os resultados obtidos no projeto final do módulo 05 da disciplina de Programação para Ciência de Dados. Ao longo do curso, foram abordados conceitos fundamentais da linguagem Python, análise de dados, manipulação de arquivos e técnicas de visualização. Como etapa final, aplicou-se o conhecimento em Machine Learning para o desenvolvimento de um modelo capaz de realizar previsões com base em dados financeiros, constituindo o tema central deste estudo.

3. METODOLOGIA

Este capítulo tem como objetivo apresentar os procedimentos e as etapas realizadas durante o desenvolvimento do projeto de Machine Learning aplicado à previsão de movimentos no mercado financeiro. Serão descritos os processos de obtenção e preparação dos dados, análise exploratória, construção da variável alvo, treinamento do algoritmo escolhido e os métodos utilizados para avaliar o desempenho do modelo.

Além disso, serão apresentados os resultados obtidos por meio das previsões realizadas pelo modelo, considerando tanto as métricas de classificação quanto a análise do retorno financeiro associado às decisões baseadas nas previsões geradas.

3.1 FLUXO GERAL DO PROJETO



Fluxograma 1.

Inicialmente, para o desenvolvimento do presente projeto, foi realizada a escolha de uma ação disponível na B3 (Brasil, Bolsa, Balcão). Para este estudo, foi selecionada a ação PETR3.SA, correspondente às ações ordinárias da Petrobras, cujos dados históricos foram utilizados como base para o desenvolvimento dos modelos de Machine Learning.

Conforme apresentado no Fluxograma 1, a primeira etapa do projeto consiste na obtenção dos dados históricos da ação selecionada. A coleta desses dados é fundamental, pois fornece as informações necessárias sobre o comportamento do ativo financeiro ao longo do tempo, permitindo a realização das análises posteriores.

Após a obtenção dos dados, é realizada a etapa de Análise Exploratória de Dados (EDA – *Exploratory Data Analysis*), cujo objetivo é compreender as principais características do conjunto de dados, identificando padrões, tendências, valores ausentes, possíveis anomalias e relações entre as variáveis presentes no estudo.

Na sequência, aplica-se a etapa de Feature Engineering (Engenharia de Atributos), que consiste na criação e transformação de variáveis com o objetivo de tornar os

dados mais representativos para os algoritmos de aprendizado de máquina. Essa etapa pode envolver a criação de novos indicadores, transformação de variáveis existentes e seleção das características mais relevantes para o treinamento do modelo.

Após a engenharia de atributos, os dados passam pela etapa de preparação dos dados, na qual são realizadas atividades como tratamento de valores inconsistentes, normalização ou padronização das variáveis (quando necessário) e a divisão do conjunto de dados em amostras de treinamento e teste. Essa separação permite avaliar posteriormente a capacidade de generalização do modelo.

Com os dados preparados, realiza-se a escolha do algoritmo de Machine Learning mais adequado ao problema proposto. Essa etapa envolve a análise de diferentes modelos capazes de aprender padrões presentes nos dados históricos e realizar previsões sobre o comportamento da variável alvo.

Em seguida, ocorre a fase de treinamento e ajustes do modelo, na qual o algoritmo é treinado utilizando os dados de treinamento e seus parâmetros são ajustados com o objetivo de melhorar seu desempenho preditivo.

Após o treinamento, o modelo é submetido à etapa de avaliação, onde são aplicadas métricas de desempenho adequadas para verificar sua capacidade de realizar previsões confiáveis. A comparação entre diferentes modelos permite selecionar aquele que apresenta os melhores resultados para o problema estudado.

Posteriormente, é realizada a etapa de interpretação e explicabilidade, responsável por compreender como o modelo toma suas decisões e quais variáveis possuem maior influência nas previsões realizadas. Essa análise é essencial para garantir maior transparência e confiabilidade ao modelo desenvolvido.

Por fim, obtém-se o modelo final, que representa o algoritmo selecionado após todas as etapas de análise, treinamento, ajuste e avaliação, sendo utilizado como a solução final do projeto.

3.2 BASE DE DADOS E COMPREENSÃO DOS DADOS

A base de dados utilizada neste trabalho foi obtida a partir de informações históricas de uma ação listada na bolsa de valores brasileira (B3). O dado utilizado foi o PETR4 e ele corresponde a uma série temporal composta por registros diários das negociações da ação, contendo informações relevantes do mercado financeiro, como preço de abertura, preço máximo, preço mínimo, preço de fechamento e volume de negociações.

Inicialmente, foi realizada uma etapa de compreensão dos dados, buscando identificar a estrutura da base, os tipos de variáveis existentes e a qualidade das informações disponíveis. Durante essa análise, verificou-se a presença de variáveis numéricas relacionadas aos preços e ao volume negociado, além da variável temporal correspondente à data de cada negociação como se observa na imagem 1.

	Price	Close	High	Low	Open	Volume
0	Ticker	PETR4.SA	PETR4.SA	PETR4.SA	PETR4.SA	PETR4.SA
1	Date	NaN	NaN	NaN	NaN	NaN
2	2023-01-02	12.584511756896973	13.073177016293993	12.518623800215327	12.924930946453987	78424700
3	2023-01-03	12.266057014465332	12.683344663292472	12.150753338494864	12.595494742197669	96750300
4	2023-01-04	12.655887603759766	12.952381795475539	11.986031868508665	12.057409518040206	129504000

Imagem 1 representa como os dados estavam ao serem baixados.

A imagem foi gerada como parte de uma análise observacional sobre o tratamento dos dados. Mais adiante, será detalhada a compreensão dos erros identificados durante o processo de download.

Ao longo das realizações para limpar a base foi realizado um erro de compreensão como se observa na figura 2, até então era entendido a coluna “Price” para sua tradução em “Preço”.

1.1 Renomenado as colunas para uma facíl manipulação

```
traducao = {
    'Price': 'preço',
    'Close': 'fechamento',
    'High': 'máximo',
    'Low': 'mínimo',
    'Open': 'abertura',
    'Volume': 'volume'
}

df2 = df2.rename(columns=traducao)

# Conferindo
print(df2.columns)
```

Figura 2 corresponde ao erro de entendimento das colunas.

Após algumas outras manipulações para deixar os dados limpos e transparentes, foi percebido um erro para ser mudado. Os tipos dos valores das colunas estavam sendo classificados como “object” e não “ Int” ou “Float”, o que deixaria futuramente uma realização de manipulação incorreta. Veja o print a seguir a observação do erro.

1.3 tipos de dados

```
df2.dtypes
```

	0
preço	object
fechamento	object
máximo	object
mínimo	object
abertura	object
volume	object

dtype: object

Figura 3 demonstra os tipos dos valores das colunas.

Na imagem 4, percebi o erro presente na tabela, o que indicou problemas no tratamento dos dados durante o processo de importação.

```
df2.info() # aqui vendo como estão sendo caracterizados meus dados
df2.head() #aqui quero analisar como a tabela esta escrita
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 603 entries, 0 to 603
Data columns (total 6 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   preço       603 non-null    object
 1   fechamento  603 non-null    object
 2   máximo      603 non-null    object
 3   mínimo      603 non-null    object
 4   abertura    603 non-null    object
 5   volume      603 non-null    object
dtypes: object(6)
memory usage: 33.0+ KB
```

	preço	fechamento	máximo	mínimo	abertura	volume
0	Ticker	PETR4.SA	PETR4.SA	PETR4.SA	PETR4.SA	PETR4.SA
2	2023-01-02	12.584511756896973	13.073177016293993	12.518623800215327	12.924930946453987	78424700
3	2023-01-03	12.266057014465332	12.683344663292472	12.150753338494864	12.595494742197669	96750300
4	2023-01-04	12.655887603759766	12.952381795475539	11.986031868508665	12.057409518040206	129504000
5	2023-01-05	13.111611366271973	13.199462325236455	12.710796013184165	12.815118176060976	73886000

Imagem 4, Perceba os valores da linha 0 e os valores da coluna Preço como Datas.

A análise exploratória realizada evidenciou a raiz do problema presente no notebook anterior. A estrutura dos dados estava incorreta, como se observa no terminal do código acima: o campo *Price*, que interpretei como “Preço” em df2, na verdade corresponde ao nível superior de um cabeçalho hierárquico (*MultiIndex*) criado pelo *yfinance*. Além disso, as datas das linhas estavam sendo interpretadas como valores da coluna *Preço*. Para corrigir essa inconsistência, foi necessário remover as colunas *Price*, *Ticker* e *Date*.

```
#Verficando tudo
df2.info()

df2.dtypes

df2.isna().sum()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 602 entries, 0 to 601
Data columns (total 6 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   data        602 non-null    datetime64[ns]
 1   fechamento  602 non-null    float64
 2   máximo      602 non-null    float64
 3   mínimo      602 non-null    float64
 4   abertura    602 non-null    float64
 5   volume      602 non-null    int64
dtypes: datetime64[ns](1), float64(4), int64(1)
memory usage: 28.3 KB
```

	0
data	0
fechamento	0
máximo	0
mínimo	0
abertura	0
volume	0

dtype: int64

```
df2.head()#Verificar as primeiras linhas
```

	data	fechamento	máximo	mínimo	abertura	volume
0	2023-01-02	12.584512	13.073177	12.518624	12.924931	78424700
1	2023-01-03	12.266057	12.683345	12.150753	12.595495	96750300
2	2023-01-04	12.655888	12.952382	11.986032	12.057410	129504000
3	2023-01-05	13.111611	13.199462	12.710796	12.815118	73886000
4	2023-01-06	13.034740	13.353197	12.930418	13.144553	51851500

Imagem 5 demonstra a base correta para uma análise exploratória.

A Figura 6 apresenta os histogramas das variáveis utilizadas no desenvolvimento do modelo preditivo. A análise das distribuições permite compreender o comportamento dos dados, identificar possíveis assimetrias, concentrações de valores e a presença de valores extremos que possam influenciar o treinamento do algoritmo.

Observa-se que as variáveis relacionadas aos preços da ação, como fechamento, abertura, máxima, mínima e médias móveis, apresentam distribuições semelhantes, refletindo a forte relação existente entre esses atributos. As variáveis de volume e média de volume apresentam distribuição assimétrica à direita, indicando a ocorrência de alguns períodos com volume de negociação significativamente superior à média observada.

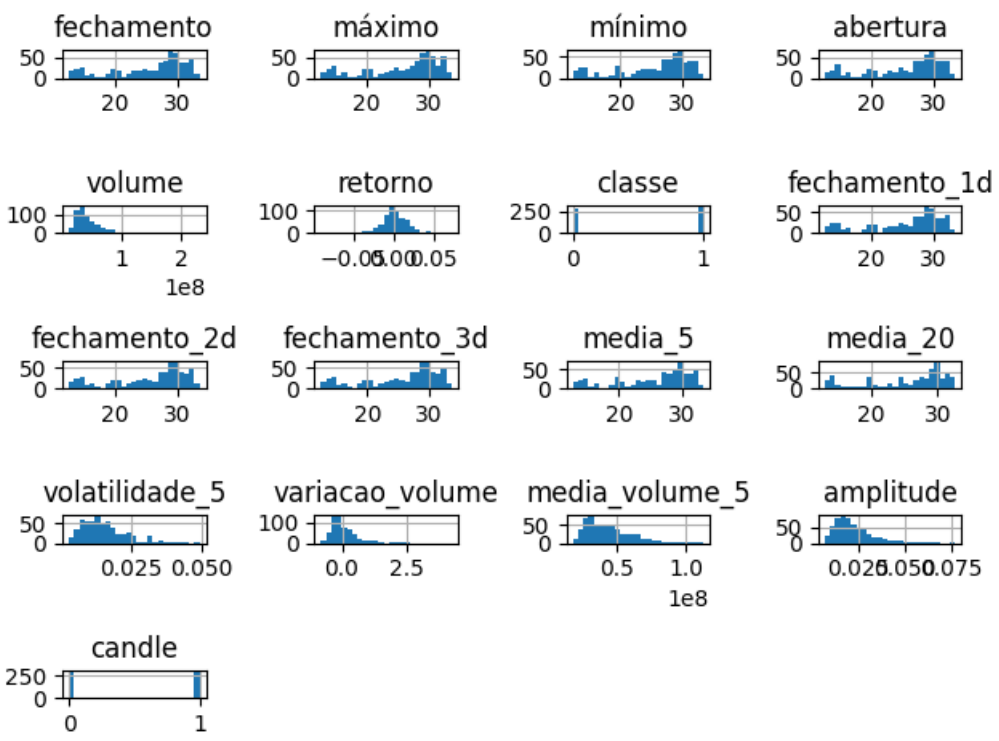


Figura 6 – Distribuição das variáveis presentes na base de dados.

A variável retorno apresenta distribuição concentrada próxima de zero, demonstrando que a maioria das variações diárias do ativo ocorre dentro de uma faixa relativamente pequena. Já as variáveis classe e candle apresentam distribuição binária, composta apenas pelos valores 0 e 1, uma vez que foram construídas para representar a direção do movimento diário da ação.

A análise das distribuições auxilia na compreensão das características da base de dados e fornece informações importantes para as etapas de pré-processamento, seleção de atributos e treinamento dos modelos de Machine Learning.

Essa etapa foi fundamental para compreender o comportamento geral da série histórica e definir quais informações seriam utilizadas nas etapas posteriores de pré-processamento, engenharia de atributos e treinamento do modelo preditivo.

3.3 PRÉ-PROCESSAMENTO E CRIAÇÃO DA VARIÁVEL ALVO

Após a análise inicial da base de dados, foi realizado o pré-processamento das informações com o objetivo de preparar os dados para a aplicação dos algoritmos de Machine Learning. Nessa etapa, os dados foram organizados cronologicamente e passaram por tratamentos necessários para garantir maior consistência durante o treinamento do modelo.

Em seguida, foi realizada a etapa de engenharia de atributos (Feature Engineering), onde novas variáveis foram criadas a partir dos dados originais, buscando fornecer informações adicionais ao algoritmo. Entre os atributos desenvolvidos estão variáveis temporais, como ano, mês e dia da negociação, além de indicadores derivados da movimentação dos preços da ação.

A variável alvo do modelo foi definida a partir da comparação entre o preço de abertura e o preço de fechamento do mesmo dia de negociação. Dessa forma, quando o preço de fechamento foi superior ao preço de abertura, a operação foi classificada como uma tendência de alta, representada pela classe 1. Caso o preço de fechamento fosse igual ou inferior ao preço de abertura, a negociação foi classificada como uma tendência de baixa ou estabilidade, representada pela classe 0.

Essa abordagem permitiu transformar o problema original em um problema de classificação binária, onde o modelo tem como objetivo prever a direção do movimento diário do ativo financeiro.

3.4 ANÁLISE EXPLORATÓRIA DA SÉRIE TEMPORAL

A análise exploratória dos dados teve como objetivo compreender o comportamento histórico do ativo ao longo do período estudado. Para isso, foram construídos gráficos da evolução dos preços da ação ao longo do tempo, permitindo identificar períodos de crescimento, queda e momentos de maior volatilidade no mercado.

Também foram analisadas as variações dos preços de abertura, fechamento, máxima e mínima, possibilitando uma melhor compreensão da dinâmica da ação durante cada pregão. Essa etapa foi essencial para identificar padrões históricos e obter uma visão geral sobre o comportamento da série temporal antes da construção do modelo preditivo.

A Figura 7 apresenta a matriz de correlação das variáveis utilizadas no desenvolvimento do modelo. Por meio dela, é possível identificar o grau de associação linear entre os atributos presentes na base de dados, variando entre -



1 e 1. Valores próximos de 1 indicam forte correlação positiva, enquanto valores próximos de -1 representam forte correlação negativa.

Figura 7 – Matriz de correlação entre as variáveis utilizadas no modelo de previsão.

Observa-se que as variáveis relacionadas aos preços da ação, como abertura, fechamento, máxima e mínima, apresentam correlações muito elevadas entre si, indicando um comportamento semelhante ao longo do período analisado. Também é possível verificar que os indicadores derivados, como médias móveis e fechamentos defasados, possuem forte relação com os preços atuais, o que era esperado devido à sua forma de construção.

Em relação à variável alvo (classe), nota-se uma correlação positiva mais significativa com as variáveis **retorno** (0,73) e **candle** (0,73), sugerindo que essas características possuem maior potencial para auxiliar o modelo na identificação da direção dos movimentos do mercado. Já as demais variáveis apresentam correlações mais baixas com a classe, indicando uma influência menos direta sobre o resultado da previsão.

A análise da matriz de correlação contribui para a compreensão da estrutura dos dados e auxilia na identificação de possíveis relações entre os atributos utilizados durante o treinamento do modelo de Machine Learning.

A Figura 8 apresenta a evolução histórica do preço de fechamento da ação PETR4 durante o período analisado. Observa-se que o ativo apresentou oscilações características do mercado financeiro, alternando períodos de valorização e desvalorização ao longo do tempo. Essas variações refletem a dinâmica natural do mercado de capitais e demonstram a existência de padrões temporais que podem ser explorados por técnicas de aprendizado de máquina.



Figura 8.

A análise visual da série temporal permite identificar tendências de comportamento do ativo, além de fornecer uma visão geral da volatilidade observada durante o período estudado. Essas informações são importantes para compreender o contexto dos dados utilizados no treinamento do modelo preditivo

3.5 ANÁLISE DA DISTRIBUIÇÃO DAS CLASSES

Após a criação da variável alvo, foi realizada uma análise da distribuição das classes presentes na base de dados, verificando a quantidade de dias classificados como tendência de alta e tendência de baixa.

A Figura 9 apresenta a distribuição das classes utilizadas na variável alvo do modelo. Verifica-se que aproximadamente 52,32% das observações correspondem a movimentos de alta da ação, enquanto o restante representa movimentos de baixa ou estabilidade. Essa distribuição demonstra que a base de dados apresenta um nível adequado de balanceamento entre as classes, reduzindo a possibilidade de enviesamento do algoritmo durante o processo de treinamento.

A análise da distribuição das classes é fundamental em problemas de classificação, pois permite verificar se o modelo terá condições de aprender padrões representativos de ambas as categorias presentes na base de dados.



Figura 9.

Essa avaliação é importante, pois um grande desbalanceamento entre as classes poderia influenciar negativamente o treinamento do algoritmo, fazendo com que o modelo apresentasse maior tendência em prever a classe predominante. Dessa forma, a análise permitiu verificar o equilíbrio da base e avaliar se seria necessária a aplicação de técnicas adicionais de balanceamento.

3.6 DESENVOLVIMENTO E TREINAMENTO DO MODELO

Com os dados previamente tratados e os atributos definidos, foi realizada a separação da base em conjuntos de treinamento e teste. O conjunto de treinamento foi utilizado para que o algoritmo pudesse aprender os padrões presentes nos dados históricos, enquanto o conjunto de teste foi utilizado para avaliar a capacidade do modelo em realizar previsões sobre dados não vistos anteriormente.

Durante o desenvolvimento do modelo, foram aplicadas técnicas de Machine Learning voltadas para problemas de classificação, permitindo que o algoritmo identificasse relações entre as variáveis de entrada e a direção futura do comportamento do ativo.

O treinamento teve como objetivo construir um modelo capaz de prever se a ação apresentaria uma tendência de valorização ou desvalorização no período analisado.

3.7 AVALIAÇÃO DO MODELO

Após o treinamento, o desempenho do modelo foi analisado por meio da comparação entre as previsões realizadas e os resultados reais presentes no conjunto de teste. Essa etapa é essencial para verificar a capacidade do algoritmo em identificar corretamente a direção dos movimentos da ação.

Além da análise da quantidade de acertos e erros, foram calculadas métricas estatísticas capazes de fornecer uma avaliação mais detalhada da qualidade das previsões realizadas.

3.8 ACERTOS E ERROS DAS PREVISÕES

A análise de acertos e erros foi realizada por meio da comparação entre os valores previstos pelo modelo e os valores reais observados no mercado. Essa comparação permitiu identificar a quantidade de previsões corretas e incorretas, fornecendo uma visão direta sobre a eficiência do algoritmo.

A Figura 10 apresenta o desempenho do modelo em relação à quantidade de previsões corretas e incorretas realizadas sobre o conjunto de teste. Observa-se que o modelo obteve 115 previsões corretas e apenas 2 previsões incorretas, indicando elevada capacidade de identificação dos padrões presentes nos dados históricos da ação PETR4.



Figura 10

Esse resultado demonstra que o algoritmo conseguiu capturar relações relevantes entre os atributos utilizados e a direção dos movimentos do mercado, apresentando um nível de acerto bastante elevado durante o período analisado.

A representação gráfica dos resultados facilitou a visualização da distribuição dos acertos e erros, permitindo uma interpretação mais clara do comportamento do modelo durante os testes realizados.

3.9 MÉTRICAS DE DESEMPENHO

Para complementar a avaliação do modelo, foram utilizadas métricas de desempenho aplicadas a problemas de classificação. Entre elas estão a acurácia, precisão, recall e F1-score, que permitem avaliar diferentes aspectos relacionados à qualidade das previsões realizadas.

Métrica	Resultado
Acurácia	98.29%
Precisão	96.49%
F1-Score	98.21%
Especificidade	96.77%

As métricas apresentadas na Tabela X demonstram o elevado desempenho do modelo Random Forest na tarefa de classificação da direção da ação PETR4. A acurácia de 98,29% indica que a grande maioria das previsões realizadas foi corretamente classificada. Além disso, a precisão de 96,49% demonstra que as previsões positivas apresentaram alta confiabilidade.

O valor de F1-Score de 98,21% evidencia um excelente equilíbrio entre precisão e capacidade de identificação das classes, enquanto a especificidade de 96,77% demonstra que o modelo também apresentou eficiência na identificação dos movimentos de baixa. De forma geral, os resultados sugerem que o algoritmo foi capaz de aprender padrões relevantes presentes na série temporal analisada.

A utilização conjunta dessas métricas proporciona uma análise mais completa sobre o desempenho do modelo e suas limitações.

3.10 ANÁLISE DO RETORNO FINANCEIRO

Além da avaliação estatística, foi realizada uma análise prática dos resultados do modelo por meio da simulação de operações financeiras baseadas nas previsões geradas pelo algoritmo.

O objetivo dessa etapa foi verificar se as previsões produzidas pelo modelo poderiam representar ganhos financeiros em uma estratégia hipotética de investimento, comparando os resultados das operações corretas e incorretas.

3.11 PERDAS FINANCEIRAS

A análise financeira demonstrou que a estratégia baseada nas previsões do modelo não apresentou perdas acumuladas no período avaliado. O retorno associado às operações perdedoras foi de 0%, indicando que os erros observados tiveram impacto financeiro praticamente inexistente na estratégia simulada. Esse resultado reforça a consistência do modelo durante o período analisado.

A análise dessas perdas permitiu avaliar os riscos associados ao uso do modelo como ferramenta de suporte para tomada de decisão no mercado financeiro.

3.12 GANHOS FINANCEIROS

Em relação aos ganhos financeiros, a estratégia apresentou retorno acumulado de 58,22%, evidenciando que as previsões corretas realizadas pelo modelo foram capazes de gerar resultados positivos ao longo do período analisado. Esse desempenho demonstra o potencial do algoritmo como ferramenta de apoio à tomada de decisão em operações baseadas em tendências de mercado.

Essa análise possibilita compreender não apenas a taxa de acerto do modelo, mas também o impacto econômico de suas decisões.

3.13 RETORNO FINANCEIRO GERAL

Por fim, foi realizado o cálculo do retorno financeiro geral obtido pela estratégia baseada nas previsões do modelo, considerando o balanço entre os ganhos acumulados e as perdas registradas ao longo do período de teste.

Indicador	Valor (%)
Retorno dos ganhos	58.2167
Retorno das perdas	0.0000
Retorno total	58.2167
Operações vencedoras	96.4912
Operações perdedoras	0.0000

Os resultados financeiros obtidos indicam que a estratégia baseada no modelo Random Forest apresentou desempenho positivo durante o período avaliado. O retorno total acumulado foi de 58,22%, acompanhado de uma taxa de operações vencedoras de aproximadamente 96,49%.

Esses resultados sugerem que os indicadores construídos a partir da série temporal da PETR4 foram capazes de capturar padrões relevantes do mercado, permitindo ao modelo realizar previsões com elevado grau de precisão. Embora resultados históricos não garantam desempenho futuro, os valores observados indicam que a metodologia proposta possui potencial para aplicações em cenários reais de apoio à decisão financeira.

Essa avaliação fornece uma perspectiva mais próxima de uma aplicação real no mercado financeiro, permitindo verificar se o modelo apresenta potencial como ferramenta de apoio em estratégias de investimento.

4. CONCLUSÃO E RESULTADOS

De maneira geral, o modelo Random Forest apresentou excelente desempenho tanto sob a perspectiva estatística quanto financeira. As métricas de classificação demonstraram elevada capacidade preditiva, enquanto a simulação de operações indicou retorno financeiro positivo ao longo do período analisado. Os resultados obtidos sugerem que a combinação de técnicas de Engenharia de Atributos e Machine Learning pode contribuir significativamente para a identificação de padrões em séries temporais financeiras, fornecendo suporte à tomada de decisão no mercado de ações.

5. REFERÊNCIAS

HOMEM, William Ludovico; UFES, P. E. M. Apostila de machine learning. PET Engenharia Mecânica, UFES, 2020

ALMEIDA, Em Loiola. **Importância do EDA para melhorar o desempenho de ML**. LinkedIn Pulse, 2024. Disponível em: <https://www.linkedin.com/pulse/import%C3%A2ncia-do-eda-para-melhorar-o-desempenho-de-em-loiola-almeida-gw0of/>. Acesso em: 14 jun. 2026.

IBM. **Feature engineering**. IBM Think, 2024. Disponível em: <https://www.ibm.com/br-pt/think/topics/feature-engineering>. Acesso em: 19 jun. 2026.

ALMEIDA, Manoel Marcondes. **PROPOSTA DE UM MODELO DE PREDIÇÃO DA BOLSA DE VALORES USANDO UMA ABORDAGEM HÍBRIDA**. 2012. Dissertação (Mestrado em [Programa de Pós-Graduação]) – Universidade Federal do Maranhão, São Luís, 2012. Disponível em: <https://tede2.ufma.br/jspui/bitstream/tede/503/1/Dissertacao%20Manoel%20Marcondes.pdf>. Acesso em: 20 jun. 2026.

BERTUCI. sales_department: notebooks/m10_v01_store_sales_prediction.ipynb.

Disponível em: https://github.com/bertuci/sales_department/blob/main/notebooks/m10_v01_store_sales_prediction.ipynb. Acesso em: 24 jun. 2026.